

EXTRAÇÃO DE CARACTERÍSTICAS DE ELETROENCEFALOGRAMA BASEADAS NA TEORIA DE GRAFOS PARA SISTEMA DE PREVISÃO DE SURTOS EPILEPTICOS

Luís Otávio L. Amorim – Aluno de Engenharia Eletrônica - IFSP SPO

Victor M. A. de Almeida – Aluno de Engenharia de Controle e Automação
- IFSP SPO

Dr. Miguel Ângelo de A. de Sousa – Docente IFSP SPO

Dra. Sara D. dos Santos – Docente IFSP SPO

Dr. Ricardo Pires – Docente ISP SPO

Introdução

A epilepsia é o distúrbio neurológico mais comum no mundo e, como a maioria dos surtos não tem causa definida a busca por sistemas que possam prever essas convulsões é importante para a autonomia dos indivíduos com essa doença.

Nesse contexto um estudo realizado pelo grupo de Tsiouris et. Al alcançou ótimos resultados utilizando a técnica de *long short-term memory* (LSTM), assim o nosso grupo de pesquisa trabalha em obter resultados similares utilizando a metodologia proposta pelo primeiro grupo.

Metodologia

A metodologia proposta por Tsiouris et. Al consiste em utilizar algumas características de eletroencefalograma (EEG) como entrada de uma rede neural do tipo LSTM, as características são:

- Vetores de transformadas de Fourier
- Vetores de transformadas de Wavelet
- Momentos estatísticos
- Correlações entre canais
- Características de Teoria de Grafos

Correlações

Cada uma das características foi retirada a partir de trechos de 5 segundos de EEG e colocada em um vetor.

Das correlações foram buscadas as máximas correlações cruzadas indexadas a defasagem entre canais além dos tempos de decorrelação de cada canal, totalizando um vetor de 157 características de correlações para cada 5 segundos de sinal.

Teoria de Grafos

- Locais:
 - Coeficiente de agrupamento: importância do nó no subgrafo
 - Centralidade da intermediação: importância do nó entre subgrafos
 - Eficiência local: grau de desconexão do nó
 - Excentricidade: grau de desconexão do nó
- Globais:
 - Raio: mínimo grau de desconexão do grafo
 - Diâmetro: máximo grau de desconexão do grafo
 - Eficiência global: desconexão média do grafo
 - Tamanho do caminho característico: grau médio de conexão do grafo
- Total: 4 globais + 72 locais = 76

Conclusões

- 233 características extraídas
- Correlações baixas
- Tempo de extração
 - Multiprocessamento
 - Numba

EDFBROWSER. EDFbrowser. 2021. Disponível em: < <https://www.teuniz.net/edfbrowser/>> . Acesso em: 20 de Agosto de 2021.

FOUNDATION, P. S. 3.9.6 Documentation. 2021. Disponível em: < <https://www.python.org>> . Acesso em: 20 de Agosto de 2021.

HOCHREITER, S.; SCHMIDHUBER, J. Long Short-Term Memory. Neural Computation, MIT Press Journals, v. 9, n. 8, p. 17351780, nov 1997. Acesso em: 20 de Agosto de 2021.

JEON, H.-J. et al. Laser speckle decorrelation time-based platelet function testing in microfluidic system. Scientific Reports 2019 9:1, Nature Publishing Group, v. 9, n. 1, p. 18, nov 2019. ISSN 2045-2322. Disponível em: < <https://www.nature.com/articles/s41598-019-52953-5>> . Acesso em: 20 de Agosto de 2021.

KOHRMAN, M. H. What is epilepsy? Clinical perspectives in the diagnosis and treatment. In: Journal of Clinical Neurophysiology. [s.n.], 2007. v. 24, n. 2, p. 8795. ISSN 07360258. Disponível em: <https://journals.lww.com/clinicalneurophys/Fulltext/2007/04000/What_is_Epilepsy/_Clinical_Perspectives_in_the.2.aspx>. Acesso em: 20 de Agosto de 2021.

NETWORKX. NetworkX. 2021. Disponível em: < <https://networkx.org/>> . Acesso em: 20 de Agosto de 2021

NUMPY. NumPy. 2021. Disponível em: < <https://numpy.org/> > . Acesso em: 20 de Agosto de 2021.

PANDAS. Pandas - Python Data Analysis Library. 2021. Disponível em: <<https://pandas.pydata.org/>> . Acesso em: 20 de Agosto de 2021.

RUBINOV, M.; SPORNS, O. Complex network measures of brain connectivity: Uses and interpretations. NeuroImage, v. 52, n. 3, p. 10591069, sep 2010. ISSN 10538119. Acesso em: 20 de Agosto de 2021.

SCARAMELLI, A. et al. Prodromal symptoms in epileptic patients: Clinical characterization of the pre-ictal phase. Seizure, W.B. Saunders, v. 18, n. 4, p. 246250, may 2009. ISSN 1059-1311. Acesso em: 20 de Agosto de 2021.

SHOEB, A. Application of machine learning to epileptic seizure onset detection and treatment. Diss. Massachusetts Institute of Technology, p. 157162, 2009. Disponível em: < <http://dspace.mit.edu/handle/1721.1/54669> > . Acesso em: 20 de Agosto de 2021.

TSIOURIS, o. et al. A Long Short-Term Memory deep learning network for the prediction of epileptic seizures using EEG signals. Computers in Biology and Medicine, Elsevier Ltd, v. 99, p. 2437, aug 2018. ISSN 18790534. Acesso em: 20 de Agosto de 2021.

URAKOV, A.; TIMERYAEV, T. Algorithms of Fast Search of Center, Radius and Diameter on Weighted Graphs. 2012. Acesso em: 20 de Agosto de 2021