

RELATÓRIO FINAL - IFSP

Nome do Bolsista: Luís Otávio Lopes Amorim

Telefone do Bolsista: (16)99357-8085

E- mail do Bolsista: luisotaviolamorim@gmail.com

Instituto Federal de Educação, Ciência e Tecnologia de São Paulo-IFSP

Rua Pedro Vicente, 625 – Canindé – São Paulo-SP

CEP: 01109-010

Telefone: 11-3775-4570

E-mail: prp@ifsp.edu.br;

Nome do Orientador: Dr. Ricardo Pires

Telefone do Orientador:

E- mail do Orientador: ricardopires29@gmail.com

Título do Projeto: Extração de Características de Eletroencefalograma Baseadas na Teoria de Grafos para Sistema de Previsão de Surtos Epiléticos

Vigência da Bolsa: 24/04/20 a 30/11/21

INTRODUÇÃO

A epilepsia é um dos distúrbios neurológicos mais comuns, afetando 65 milhões de pessoas no mundo (EPILEPSY FOUNDATION, 2021; WORLD HEALTH ORGANIZATION, 2019). Ela é diagnosticada após uma pessoa ter tido ao menos dois surtos sem nenhuma outra causa médica conhecida.

As convulsões sofridas pelos pacientes ocorrem devido a distúrbios na atividade elétrica do cérebro. Esses distúrbios podem estar relacionados a lesões no cérebro ou mesmo causas genéticas, ainda assim, na maioria dos casos a causa é desconhecida (SHAFER; SIRVEN, 2020). Surtos podem ser desde pequenos lapsos de atenção até convulsões prolongadas e variam, em frequência, desde menos de um por ano até vários por dia (WORLD HEALTH ORGANIZATION, 2019).

A atividade cerebral é medida na forma do chamado eletroencefalograma (EEG), usando-se eletrodos metálicos posicionados na superfície do crânio. O EEG manifesta-se, dessa forma, como ondas ao longo do tempo, uma para cada eletrodo (também chamados de canais), representando as sinapses das comunicações entre as células cerebrais. Esse exame é utilizado nos principais testes para diagnóstico de epilepsia, além de

outros distúrbios neurológicos (MAYO FOUNDATION FOR MEDICAL EDUCATION AND RESEARCH, 2020).

Desta forma os períodos de atividade cerebral são definidos como ictal, correspondendo ao período de um surto; pré-ictal, que precede imediatamente um surto; pré-ictal, imediatamente a seguir de um surto e interictal, período distante de surtos (MULA; MONACO, 2011).

Os tratamentos para a doença são baseados em medicamentos ou cirurgia. Eles são ineficazes para a maioria dos pacientes (GADHOUMI et al., 2016). Dessa forma há grande interesse no desenvolvimento de sistemas para a previsão de surtos epiléticos para serem utilizados no dia a dia dos pacientes. Se um sistema desse tipo advertir um paciente sobre a possível chegada de um surto com uma boa antecedência e boa precisão, esse paciente pode colocar-se em situação de segurança, como parar de dirigir um carro. Além disso, para os pacientes para os quais os medicamentos são eficazes, eles podem ser administrados apenas após a advertência desse sistema, minimizando assim efeitos colaterais.

Tsiouris et al. realizaram um trabalho muito promissor utilizando uma rede neural do tipo *Long Short Term Memory* (LSTM) (HOCHREITER; SCHMIDHUBER, 1997). Na montagem dos vetores (lista ordenada de valores) daquele trabalho, foram combinadas diversas características extraídas de EEG, como momentos estatísticos e outras do domínio temporal, resultados de Transformada de Fourier e de Wavelet, valores de correlação e medidas baseadas em Teoria de Grafos. Dentre essas características, o grupo de pesquisa não possui conhecimentos e métodos para analisar apenas aquelas referentes à correlação dos sinais e à Teoria dos Grafos que foram detalhadas por Rubinov e Sporns (2010) e Urakov e Timeryaev (2012).

OBJETIVO ou PROPOSIÇÃO

O objetivo deste projeto é a obtenção do domínio de todo o processo de extração de características de sinais de EEG baseadas em Teoria dos Grafos. Após o conhecimento teórico de cada uma das características, objetiva-se construir um programa de computador em linguagem Python (PYTHON SOFTWARE FOUNDATION, 2020) utilizando principalmente a biblioteca livre NetworkX (NETWORKX, 2021).

ATIVIDADES REALIZADAS

Atividade 1 – Estudo bibliográfico: Leitura dos artigos de Rubinov e Sporns (2010) e de Urakov e Timeryaev (2012) para entender as definições de cada uma das características baseadas em Teoria de Grafos utilizadas por Tsiouris et al. (2018). Pesquisa sobre correlações e tempo de decorrelação entre dois sinais;

Atividade 2 – Testes iniciais: Criação de algoritmos para realizar testes com a biblioteca NetworkX e verificação de resultados obtidos com valores teóricos esperados para as características sendo analisadas;

Atividade 3 – Programa de computador para extração de características: Criação do programa que faz o cálculo das correlações, dos tempos de correlações, de todas as características de Teoria de Grafos e armazena todos esses dados em novos arquivos no formato Comma Separated Values (CSV);

Atividade 4 – Análise da metodologia de separação de vetores para treino e teste: Discussão sobre a forma com que os vetores são separados para treino e teste na metodologia proposta por Tsiouris et. Al, testes comparando a metodologia proposta com a metodologia considerada correta pelo grupo de pesquisa.

RESULTADOS OBTIDOS

Os dados utilizados para esse trabalho foram obtidos da base de dados *PhysioNet*, mais especificamente o conjunto *CHB-MIT Scalp EEG Database* (PHYSIONET, 2010) descrito inicialmente por Shoeb (2009). Eles foram baixados do banco de dados no formato European Data Format (EDF) porém antes de serem processados foram convertidos para CSV.

A primeira etapa do processo de extração é o cálculo do módulo das correlações cruzadas entre os sinais dos canais do EEG. Isso, pois, além de serem valores necessários, as correlações são utilizadas nas construções dos grafos. Um resultado interessante que pode ser visto é que essas correlações são sempre muito baixas, a exemplo disso a figura 1 mostra as correlações entre canais para os primeiros 5 segundos de EEG do primeiro paciente.




Figura 1: Mapa de calor das correlações entre canais dos primeiros 5 segundos do paciente 1
(Fonte: Autor)

Como pode ser visto os valores de correlações não ultrapassam 0,3, sendo que o valor máximo de uma correlação é 1, mostrando que os sinais estão muito pouco correlacionados. Por mais que a figura mostra apenas um intervalo de um paciente, isso se manteve constante para outras análises.

A segunda característica de conectividade é o tempo de decorrelação dos sinais. Esse tempo foi calculado apenas para as autocorrelações e é definido como o tempo que demora para que a correlação atinja um valor menor que 0,5.

Por fim, foram calculadas as características de Teoria dos Grafos. O grafo criado é do tipo não direcionado e com pesos. Cada nó do grafo representa um dos sinais e o peso da conexão entre dois nós é a correlação entre os dois sinais. As características extraídas dos grafos e suas definições podem ser vistas na tabela 1.

Nome	Tipo	Definição
Tamanho do caminho característico.	Global	Média das médias dos caminhos mais curtos do grafo
Eficiência global.	Global	Média das médias dos pesos saindo de cada nó.
Raio.	Global	Excentricidade mínima.
Diâmetro.	Global	Excentricidade máxima.
Excentricidade.	Local	Distância máxima de um dado nó a qualquer outro do grafo.
Centralidade da intermediação.	Local	Soma das frações de todos os caminhos mais curtos que passam por um nó.
Eficiência local.	Local	Média das eficiências globais dos subgrafos induzidos por nós vizinhos de um nó.
Coeficiente de agrupamento.	Local	Fração de triângulos ao redor de um nó, normalizado, utilizando o peso das conexões desse nó.

Tabela 1: Definição das características baseadas em Teoria dos Grafos (Fonte: Autor)

As características estão divididas em globais, referentes ao grafo como um todo, e locais, referente a cada um dos nós. Após serem extraídas, elas

foram armazenadas separadamente das características de conectividade cerebral. Além disso, foram salvas também as distribuições das características locais, ou seja, suas médias.

Dessa forma obtiveram-se três conjuntos diferentes, um com as características de conectividade cerebral, outro com todas as características de Teoria dos Grafos e o último com as quatro características globais e quatro distribuições de características locais.

Esses três conjuntos de vetores foram enviados para outro bolsista do grupo utilizar em uma rede neural criada da mesma forma que aquela utilizada por Tsiouris et al.. Além das características aqui extraídas, também foram utilizadas aquelas dos domínios do tempo e da frequência.

As figuras 2, 3 e 4 indicam os resultados de previsão de surtos epiléticos obtidos para o paciente 1 utilizando respectivamente apenas características de domínio temporal e das frequências, as características do domínio do tempo, das frequências e de Teoria de Grafos e, por fim, todas as características. Nessas figuras, o gráfico em vermelho representa os valores esperados e o branco é o resultado obtido. Por fim, a figura 5 é uma comparação das acurácias, especificidades e sensibilidades dos três testes, sendo a característica mais importante a sensibilidade, que indica a capacidade da rede de identificar o período pré-ictal de forma correta.




Figura 2: Resultados obtidos utilizando características de tempo e frequência
(Fonte: bolsista Victor Manuel Araújo de Almeida)



Figura 3: Resultados obtidos utilizando características de tempo, frequência e Teoria de Grafos (Fonte: bolsista Victor Manuel Araújo de Almeida)




Figura 4: Resultados obtidos utilizando características de tempo, frequência, Teoria de Grafos e correlações (Fonte: bolsista Victor Manuel Araújo de Almeida)

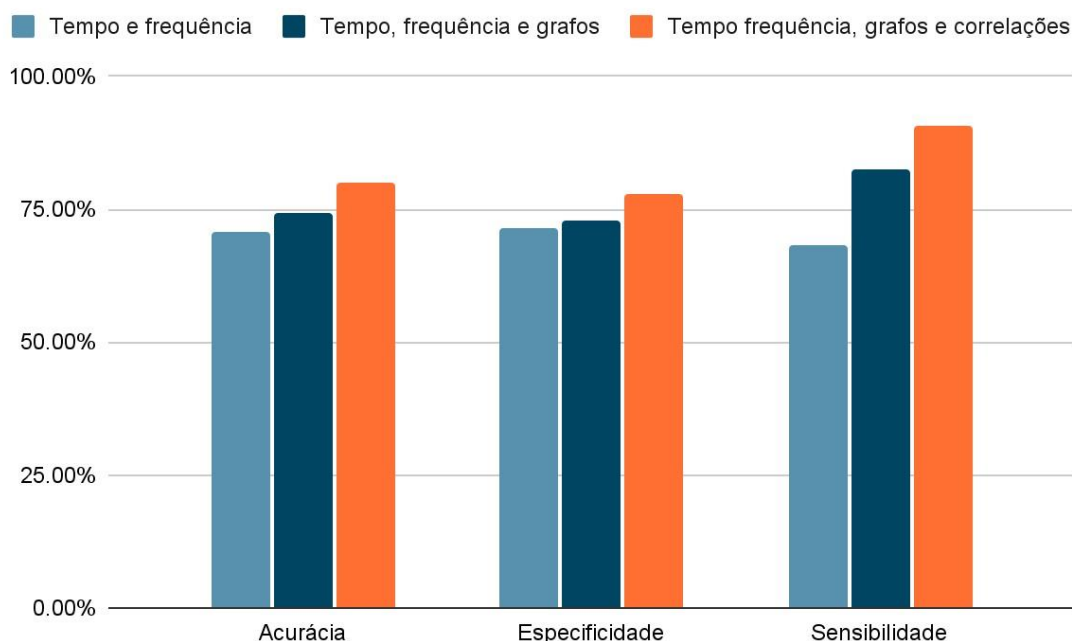


Figura 5: Comparação dos resultados obtidos (Fonte: Autor)

Observando a comparação entre os resultados, é visível que a adição tanto das características de teoria dos grafos, quanto das correlações melhoram o desempenho da rede. Em específico a adição em conjunto das duas categorias traz o melhor resultado, com uma sensibilidade de aproximadamente 90% neste paciente.

Analisando os resultados obtidos e comparando com os resultados de Tsiouris et. al. chegamos à conclusão que talvez a diferença desses resultados seja por causa da forma de separação do conjunto de treino e conjunto de teste da rede.

No trabalho deles, vetores de todas as crises são embaralhados e depois divididos em conjunto de treino e teste, isso faz com que possa haver dois vetores da mesma crise, um no conjunto de treino e um no de teste de forma que o vetor do conjunto de treino pode ter alguma informação muito importante sobre aquela crise, sendo uma forma de passar as informações do conjunto de teste durante o treinamento, algo que não pode ser feito ao trabalhar com redes neurais, esse método de separação pode ser visto na figura 6. O grande problema desse método de separação é que em uma aplicação real não temos nenhuma informação sobre a próxima crise, então não podemos colocar informações sobre ela para o conjunto de treino.

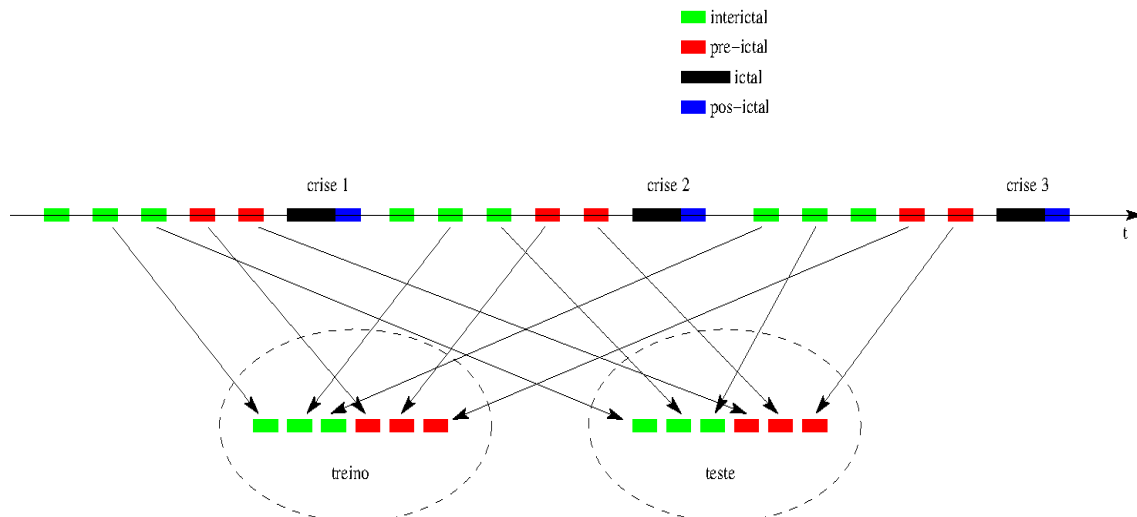


Figura 6: Método de separação utilizado por Tsiouris et. al. (Fonte: Prof. Dr. Ricardo Pires)

A metodologia utilizada por nós elimina isso ao selecionar os vetores da última crise do paciente como os vetores do conjunto de teste e deixar todos os outros vetores para serem embaralhados formando o conjunto de treino, assim não há vetores da crise de teste no conjunto de treino, a figura 7 mostra o método de separação de vetores utilizado.

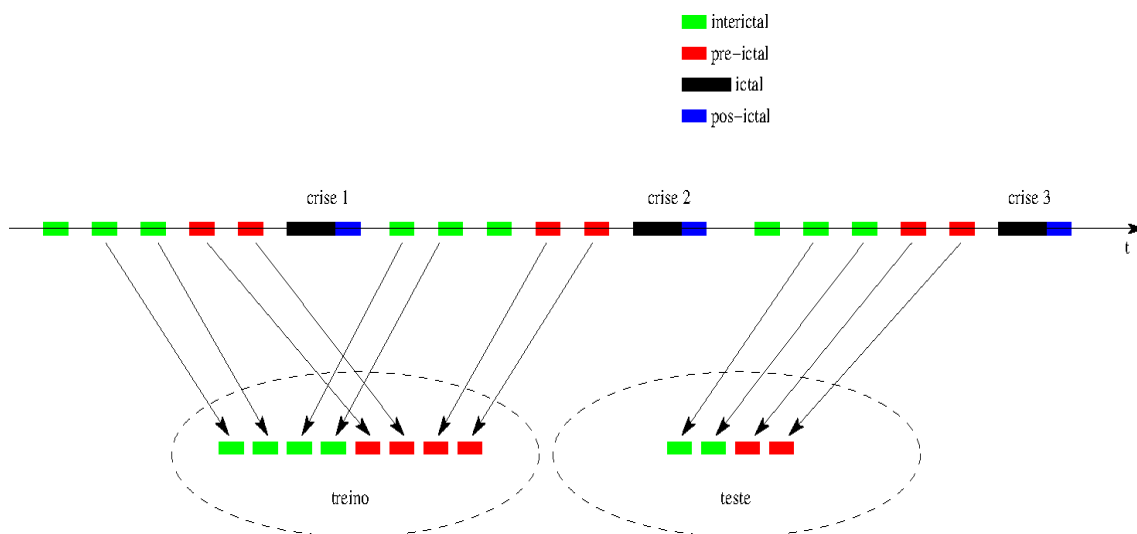


Figura 7: Método de separação utilizado pelo nosso grupo de pesquisa (Fonte: Prof. Dr. Ricardo Pires)

Pensando nisso decidimos comparar as acurácias de treinamento utilizando os dois métodos diferentes para cada grupo de características no vetor. A tabela 1 mostra uma comparação inicial desses dois métodos, essa comparação apoia a hipótese proposta.

	método de separação treino-teste	
	de Tsiouris	recomendado
com FFT	100,00%	55,32%
com momentos estatísticos	45,83%	51,06%
com wavelets	100,00%	51,06%

Tabela 1: Comparação entre os dois métodos (Fonte: Prof. Dr. Ricardo Pires)

Vale notar que, por se tratar de uma classificação binária (vetor é pré-ictal ou é interictal) a pior acurácia possível é de 50%, caso em que a rede simplesmente chuta a mesma classe sempre.

Com esses resultados em mãos realizamos mais testes, para os quatro primeiros pacientes treinamos uma rede neural utilizando apenas os vetores de FFT com duas camadas de 128 células LSTM e uma camada totalmente conectada com um neurônio para a saída. Para cada paciente fizemos o processo de treino e teste 10 vezes, de forma que os conjuntos de treino e teste sempre fossem aleatorizados e diferentes, utilizando como métrica de erro o erro quadrático médio e o otimizador Adam com 1000 épocas de treinamento os resultados podem ser vistos nas tabelas 2 a 5.

Treino	TP	FP	TN	FN	Acurácia	Sensibilidade	Especificidade
1	9	0	25	13	73%	41%	100%
2	0	0	22	25	47%	0%	100%
3	27	5	15	0	89%	100%	75%
4	25	0	22	0	100%	100%	100%
5	0	0	23	24	49%	0%	100%
6	25	2	20	0	96%	100%	91%
7	17	0	28	2	96%	89%	100%
8	21	0	26	0	100%	100%	100%
9	0	0	23	24	49%	0%	100%
10	1	0	22	24	49%	4%	100%
Média	12,5	0,7	22,6	11,2	75%	53%	97%

Tabela 2: Resultados para o paciente 1 (Fonte: Autor)

Treino	TP	FP	TN	FN	Acurácia	Sensibilidade	Especificidade
1	4	0	11	10	60%	29%	100%
2	9	7	6	3	60%	75%	46%
3	3	0	9	13	48%	19%	100%
4	1	0	10	14	44%	7%	100%
5	13	0	12	0	100%	100%	100%
6	10	7	4	4	56%	71%	36%
7	11	4	10	0	84%	100%	71%
8	9	1	12	3	84%	75%	92%
9	0	0	10	15	40%	0%	100%
10	12	0	10	3	88%	80%	100%
Média	7,2	1,9	9,4	6,5	66%	56%	85%

Tabela 3: Resultados para o paciente 2 (Fonte: Autor)

Treino	TP	FP	TN	FN	Acurácia	Sensibilidade	Especificidade
1	23	5	0	0	82%	100%	0%
2	14	5	3	6	61%	70%	38%
3	19	9	0	0	68%	100%	0%
4	19	9	0	0	68%	100%	0%
5	1	4	4	19	18%	5%	50%
6	19	6	0	3	68%	86%	0%
7	15	9	2	2	61%	88%	18%
8	15	9	1	3	57%	83%	10%
9	18	10	0	0	64%	100%	0%
10	18	10	0	0	64%	100%	0%
Média	16,1	7,6	1	3,3	61%	83%	12%

Tabela 4: Resultados para o paciente 3 (Fonte: Autor)

Treino	TP	FP	TN	FN	Acurácia	Sensibilidade	Especificidade
1	7	9	8	3	56%	70%	47%
2	10	2	15	0	93%	100%	88%
3	4	4	8	11	44%	27%	67%
4	7	9	5	6	44%	54%	36%
5	9	1	8	9	63%	50%	89%
6	16	0	10	1	96%	94%	100%
7	12	0	15	0	100%	100%	100%
8	0	0	16	11	59%	0%	100%
9	7	8	3	9	37%	44%	27%
10	4	1	12	10	59%	29%	92%
Média	7,6	3,4	10	6	65%	57%	75%

Tabela 5: Resultados para o paciente 4 (Fonte: Autor)

Para esses pacientes ainda não realizamos os testes pelo método proposto por nosso grupo, mas esses resultados obtidos corroboram com a hipótese de que talvez o embaralhamento dos vetores possa influenciar positivamente na acurácia. Além disso, algo a se notar é que, por mais que

várias vezes os resultados foram ruins, durante o treino foi percebido que o erro depois de um tempo começa a aumentar, talvez um indicativo de overfitting, algo que pretendemos analisar e remover usando algum método de parada de treinamento precoce.

Assim, fica definido como próximos passos para a pesquisa continuar estudando essa hipótese comparando o resultado do método proposto com o resultado do método de Tsiouris et. al. utilizando cada conjunto de características separadamente e todos eles em conjunto também.

REFERÊNCIAS

EPILEPSY FOUNDATION. **Epilepsy Foundation**. Disponível em: <<https://www.epilepsy.com/>>. Acesso em: 30 maio. 2021.

GADHOUMI, K. et al. Seizure prediction for therapeutic devices: A review. **Journal of Neuroscience Methods**, v. 260, p. 270–282, fev. 2016.

HOCHREITER, S.; SCHMIDHUBER, J. Long Short-Term Memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 1 nov. 1997.

MAYO FOUNDATION FOR MEDICAL EDUCATION AND RESEARCH. **EEG (electroencephalogram)**. Disponível em: <<https://www.mayoclinic.org/tests-procedures/eeg/about/pac-20393875>>. Acesso em: 30 maio. 2021.

MULA, M.; MONACO, F. Ictal and Peri-Ictal Psychopathology. **Behavioural Neurology**, v. 24, n. 1, p. 21–25, 1 jan. 2011.

NETWORKX. **NetworkX — Network Analysis in Python**. Disponível em: <<https://networkx.org/>>. Acesso em: 1 jun. 2021.

PHYSIONET. **CHB-MIT Scalp EEG Database**. Disponível em: <<https://physionet.org/content/chbmit/1.0.0/>>.

PYTHON SOFTWARE FOUNDATION. **Python**. Disponível em: <<https://www.python.org/>>. Acesso em: 1 jun. 2021.

RUBINOV, M.; SPORNS, O. Complex network measures of brain connectivity: Uses and interpretations. **NeuroImage**, v. 52, n. 3, p. 1059–1069, set. 2010.

SHAFER, P., O.; SIRVEN, J., I. **About Epilepsy: The Basics**. Disponível em:

<<https://www.epilepsy.com/learn/about-epilepsy-basics>>. Acesso em: 30 maio. 2021.

SHOEB, A. H. **Application of machine learning to epileptic seizure onset detection and treatment**. Tese (Doutorado)—[s.l.] Massachusetts Institute of Technology, 2009.

TSIOURIS, K. M. et al. A Long Short-Term Memory deep learning network for the prediction of epileptic seizures using EEG signals. **Computers in Biology and Medicine**, v. 99, p. 24–37, ago. 2018.

URAKOV, A.; TIMERYAEV, T. Algorithms of Fast Search of Center, Radius and Diameter on Weighted Graphs. 2012.

WORLD HEALTH ORGANIZATION. **Epilepsy**, 2019. Disponível em: <<https://www.who.int/news-room/fact-sheets/detail/epilepsy>>. Acesso em: 30 maio. 2021

Assinatura do orientador:

Assinatura do bolsista: Luís Otávio L. Amorim